Otimização de Joins aplicado à integração dos datasets do NLST

Aluno: Lucas Piovani Ferreira, 13836813

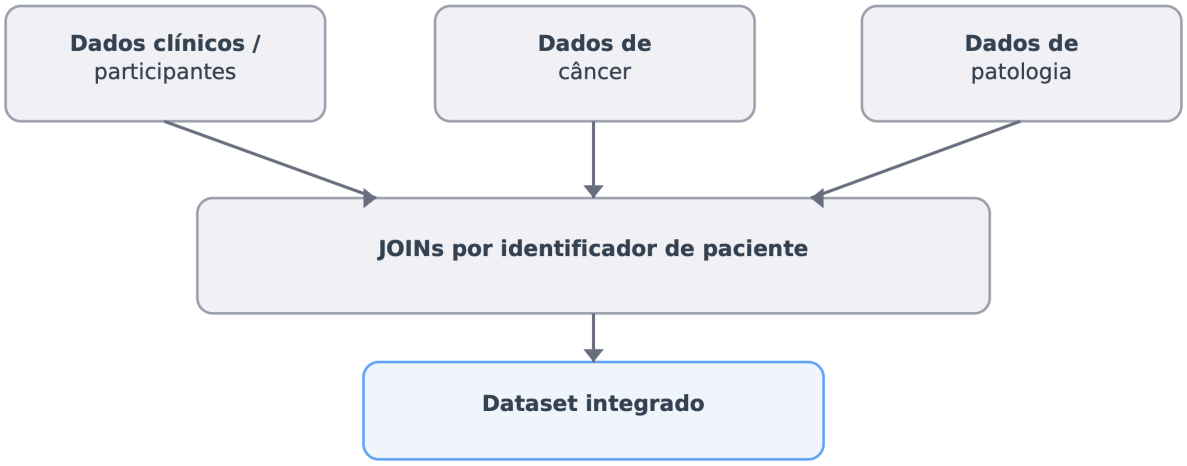
Disciplina: Teoria e Técnica de Construção de SGBDs

Contexto: proposta baseada na etapa de integração já realizada no projeto de exploração do National Lung Screening Trial (NLST).

Ideia central: Integração dos datasets do NLST como problema de JOIN

1. Ideia Central

O trabalho propõe estudar a **otimização de JOINs** utilizando como estudo de caso a integração de diferentes datasets do **National Lung Screening Trial (NLST)**. A motivação surge diretamente do trabalho já realizado no projeto: diferentes conjuntos de dados do NLST possuem informações complementares sobre participantes, câncer e patologia, e a integração dessas informações exige a identificação de pacientes em comum e o relacionamento entre as entidades.



Em vez de desenvolver uma nova aplicação, o artigo transforma essa etapa de integração em um problema clássico de Sistemas de Gerenciamento de Bancos de Dados: como um SGBD decide executar JOINs e como diferentes

estratégias de execução afetam o custo das consultas? O estudo pode ser realizado de forma experimental, utilizando consultas SQL sobre os datasets já preparados e analisando seus planos de execução

2. Problema de Pesquisa

> Como diferentes estratégias de execução e otimização de JOINs afetam o desempenho de consultas que integram os datasets clínicos, de câncer e de patologia do NLST?

A questão é especialmente adequada à disciplina porque permite relacionar diretamente conceitos teóricos (álgebra relacional, cardinalidade, estimativa de custo, algoritmos de JOIN, ordem das operações e otimização de consultas) com um workload real aplicado a dados da área médica.

3. O que é o NLST e quais são seus dados?

O National Lung Screening Trial (NLST) é um grande estudo clínico voltado à investigação de estratégias de rastreamento para câncer de pulmão. O conjunto de dados disponibilizado pelo projeto reúne diferentes tipos de informações relacionadas aos participantes, incluindo dados clínicos e demográficos, informações sobre câncer, exames de imagem, materiais de patologia e dados de obituário.

Para este artigo, o foco estará nos datasets que já foram explorados no projeto de iniciação científica, orientado pela Profa. Dra. Agma Juci Machado Traina, especialmente aqueles relacionados a participantes, câncer e patologia. Esses conjuntos apresentam relações que podem ser estabelecidas por identificadores de pacientes ou outros identificadores compartilhados, permitindo construir consultas integradas.

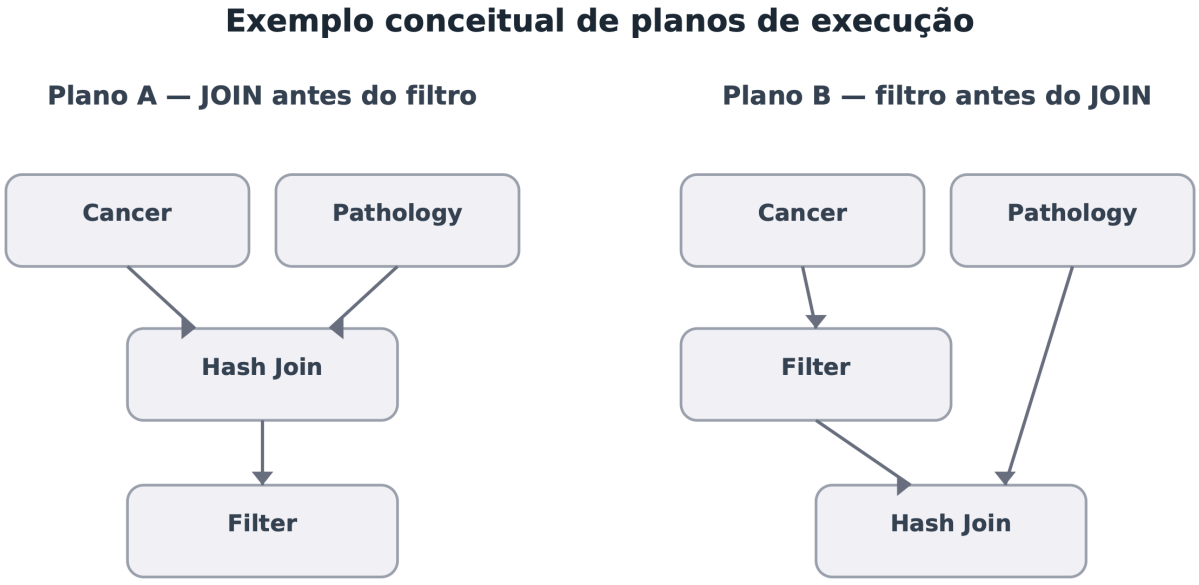
Durante a exploração do NLST, foram identificados pacientes presentes em diferentes datasets e construídos catálogos para organizar os dados de patologia e câncer. Também foi estruturado um catálogo de metadados, contendo informações sobre arquivos, atributos, identificadores, tipos de dados e relações relevantes. Esse material será utilizado para definir o esquema experimental e documentar as relações entre as fontes.

Assim, o artigo não precisará criar um cenário artificial: a integração já realizada fornece um caso concreto de workload para estudar o comportamento de JOINs em um SGBD.

4. Por que JOIN optimization?

Uma consulta relativamente simples pode envolver várias relações. Por exemplo, podemos querer encontrar informações de patologia apenas para pacientes que apresentam determinada característica relacionada ao câncer. Uma consulta desse tipo pode ser expressa em SQL, mas internamente o SGBD precisa decidir como realizar os JOINs e em que ordem executar filtros e outras operações.

Considere, conceitualmente, uma consulta que relaciona os datasets de câncer de pulmão e de pathologia. O SGBD pode realizar o JOIN sobre todas as tuplas e aplicar o filtro posteriormente, ou pode aplicar o filtro primeiro, reduzindo a quantidade de registros que participará do JOIN. A segunda estratégia pode reduzir significativamente o custo quando o filtro é seletivo.



A comparação investiga como a redução da cardinalidade antes do JOIN pode alterar o custo da execução.

5. Estratégias de JOIN a serem investigadas

O artigo pode investigar diferentes algoritmos e estratégias, de acordo com o que estiver disponível no SGBD escolhido (como PostgreSQL ou DuckDB) e com o escopo definido para o trabalho.

5.1. Hash Join

Construção de uma estrutura hash sobre uma das relações e busca das correspondências na outra. É particularmente relevante para joins por igualdade, como os realizados sobre identificadores de pacientes.

5.2. Nested Loop Join

Uma relação é percorrida e, para cada tupla, são procuradas correspondências na outra relação. Pode ser vantajoso em determinados cenários, especialmente quando uma das relações é pequena ou quando existe uma estrutura de acesso adequada.

5.3. Merge Join / Sort-Merge Join

As relações são organizadas de acordo com a chave de junção e percorridas de forma ordenada. Pode ser relevante quando os dados já estão ordenados ou quando a ordenação é aproveitada pelo plano.

5.4. Ordem dos JOINs

Em consultas envolvendo três ou mais relações, a ordem escolhida pelo otimizador pode alterar significativamente o tamanho das relações intermediárias e, consequentemente, o custo total.

---

6. Parte prática

A parte prática pode ser relativamente pequena e focada em experimentação, para que o artigo possa ser escrito até o encerramento da disciplina.

O objetivo será preparar um conjunto de consultas representativas do processo de integração do NLST, executar essas consultas em um SGBD e analisar os planos de execução e as métricas obtidas.



Relacionar teoria de otimização de consultas a um caso biomédico real

6.1. Workload de Consultas

Consulta	Operação	Questão investigada

Q1	JOIN entre Cancer e Pathology por patient_id	Custo básico de integração
Q2	JOIN + filtro seletivo em Cancer	Efeito de aplicar filtros antes do JOIN
Q3	JOIN + filtro em Pathology	Impacto da seletividade da outra relação
Q4	Cancer + Pathology + Participant	Ordem de JOINs e cardinalidade intermediária
Q5	Consulta com agregação após JOIN	Interação entre JOIN e agregação

6.2. Variáveis e métricas

Métrica	**Interpretação**
Tempo de execução	Tempo total necessário para executar a consulta
Cardinalidade intermediária	Quantidade de tuplas produzidas entre etapas do plano
Dados lidos / I/O	Volume de dados acessado durante a execução
Memória	Memória utilizada por estruturas como hash tables ou operações ordenação
Algoritmo de JOIN	Estratégia escolhida pelo otimizador para cada junção
Plano de execução	Operadores e ordem das operações realizadas pelo SGBD

7. Experimentos possíveis

7.1. Experimento 1

- JOIN sem filtro vs. JOIN com filtro.
    - Executar consultas equivalentes em que uma versão filtra uma relação antes da junção e outra aplica o filtro posteriormente. O objetivo é observar o efeito da redução da cardinalidade.

7.2. Experimento 2

- Diferentes tamanhos das relações.
    - Utilizar subconjuntos de diferentes tamanhos para verificar como o comportamento dos algoritmos muda conforme o volume de dados.

7.3. Experimento 3

- Diferentes ordens de JOIN.
    - Utilizar três ou mais relações para observar como a ordem das junções influencia as relações intermediárias e o custo do plano.

7.4. Experimento 4

- Análise do plano escolhido pelo SGBD.
    - Utilizar comandos como EXPLAIN e/ou EXPLAIN ANALYZE, quando disponíveis, para relacionar o comportamento observado às decisões do otimizador.

7.5. Experimento 5

- Estatísticas e estimativa de cardinalidade.
    - Investigar, se suportado pelo SGBD escolhido, como estatísticas sobre as relações influenciam a escolha do plano.

---

8. Perguntas a serem respondidas

1. Como diferentes algoritmos de JOIN afetam o desempenho das consultas de integração dos datasets do NLST?
2. Qual é o impacto da aplicação de filtros antes dos JOINs sobre a cardinalidade intermediária e o tempo de execução?
3. Como a ordem dos JOINs influencia o custo das consultas envolvendo três ou mais datasets?
4. Em que medida as estimativas do otimizador correspondem ao comportamento observado durante a execução?
5. Como o aumento do volume de dados modifica a escolha e o desempenho das estratégias de JOIN?

---

9. Hipótese

A expectativa inicial é que a redução da cardinalidade antes de operações de JOIN possa diminuir o custo de execução, especialmente quando os filtros são seletivos. Também se espera que a ordem das junções seja relevante em

consultas envolvendo múltiplas relações, pois diferentes ordens podem produzir relações intermediárias de tamanhos muito distintos.

Entretanto, essas expectativas serão avaliadas empiricamente. O objetivo não é assumir previamente qual algoritmo ou plano é melhor, mas compreender por que o SGBD escolhe determinada estratégia e em quais condições essa escolha produz diferentes custos de execução.

---

10. Viabilidade até o final da disciplina

A proposta é particularmente viável porque a etapa mais trabalhosa de compreensão dos dados já foi realizada no projeto de iniciação científica. Já foram exploradas as estruturas dos datasets do NLST, identificados pacientes em comum e construídos catálogos e relações para integrar dados de patologia e câncer.

O trabalho adicional fica concentrado em transformar essa integração em um workload de SGBD, preparar as consultas, executar os experimentos, coletar os planos e métricas e interpretar os resultados.

Etapa	Atividade
1	Revisão bibliográfica sobre processamento e otimização de JOINs
2	Definição do SGBD e preparação dos datasets/workload
3	Definição das consultas e cenários experimentais
4	Execução dos testes e coleta dos planos/métricas
5	Análise dos resultados e relação com a teoria de SGBDs
6	Redação e revisão do artigo

Observação: o NLST será utilizado como estudo de caso e workload experimental. A contribuição principal permanece no domínio de SGBDs, com foco no processamento e na otimização de consultas, especialmente na execução de JOINs. Porém, ainda é interessante o uso desses dados médicos, pois eles serão o foco do meu estudo de mestrado caso eu venha a ser aceito no início do próximo ano.